



LABDATA

*Quem sabe lidera.*PÓS-GRADUAÇÃO E MBA · ANALYTICS, INTELIGÊNCIA ARTIFICIAL
E DATA SCIENCE

Estudo de Caso 3

Métodos de Projeção: Modelos Baseados em Árvores

Prof. Ângelo Chiode

Agosto de 2026

Case D | Custo em Seguro Saúde

● CONTEXTO E MISSÃO

Uma empresa de plano de saúde precisa entender o que determina o custo anual de seus segurados, de modo a apoiar a precificação e a gestão de risco da carteira. Os custos variam muito entre segurados, em função de fatores demográficos, biométricos e de hábitos.

A missão do estudo é responder as seguintes perguntas:

- **Predição:** qual algoritmo prevê o custo anual com o menor erro possível e, a partir dele, qual custo um novo segurado tende a gerar, com base em suas características, supondo que siga os mesmos padrões observados na base.
- **Interpretação:** quais características de um segurado mais influenciam o custo anual e em que direção cada uma atua sobre as previsões do modelo.

● ORIENTAÇÕES TÉCNICAS

- 1 **Divisão dos dados:** separe a base em conjuntos de **treino** e **teste externo** (sugestão: 80% / 20%), fixando uma semente aleatória para

garantir a reprodutibilidade.

- 2 **Pré-processamento:** crie variáveis dummy para as variáveis qualitativas (codificação one-hot), ajustando a transformação no conjunto de treino e aplicando-a ao conjunto de teste externo.
- 3 **Ajuste dos modelos:** teste diferentes algoritmos baseados em árvores (árvore de regressão, *random forest* e variantes de *boosting*), otimizando os hiperparâmetros de cada um por busca aleatória (*random search*) com validação cruzada (*k-fold*) no conjunto de treino.
Obs.: o uso da regressão linear regularizada e do *CatBoost* é opcional; caso queira testá-los, note que a regressão linear regularizada exige a padronização das variáveis explicativas quantitativas; e o *CatBoost* não requer codificação prévia das variáveis explicativas qualitativas.
- 4 **Comparação e escolha do modelo:** compare os modelos pelo RMSE médio nas *folds* de teste interno, verificando a estabilidade em relação ao treino e ao teste externo (indício de superajuste). Escolha um modelo final e reajuste-o na base completa.
- 5 **Avaliação de desempenho:** avalie o modelo escolhido no conjunto de teste externo por meio de RMSE, MAE, MAPE e R^2 , e examine graficamente o comportamento dos resíduos.
- 6 **Interpretabilidade:** avalie a importância das variáveis por redução de impureza, por permutação e pelos valores SHAP, comparando se os métodos apontam para conclusões semelhantes. Utilize o gráfico de dispersão dos valores SHAP (*beeswarm*) para identificar a direção do efeito de cada variável.
- 7 **Predição:** utilize o modelo final para prever o custo anual de uma ou mais novas observações, definindo os valores de suas características.

● ENTREGÁVEIS

Os seguintes arquivos devem ser entregues por **todos os membros** do grupo:

- **Apresentação:** slides (extensão .pdf, .html ou .pptx) com sumarização de resultados e conclusões, para público híbrido (técnico/gestão), seguindo o *template* disponibilizado.
- **Documentação técnica:** *notebook* de Python (extensão .ipynb) com todo o código utilizado na resolução do case, já compilado (células executadas e com as saídas visíveis).
- **Relatório de participação:** planilha (extensão .xlsx) que registra as contribuições individuais dos membros do grupo, seguindo o *template* disponibilizado.

Atenção! Todos os membros do grupo devem entregar exatamente os **mesmos arquivos**, ou seja, com nomenclatura e conteúdo idênticos. Caso haja divergências entre os arquivos submetidos, haverá penalidade de nota.

● DADOS

A base de dados está na **visão segurado**: cada linha representa um segurado distinto, com seus fatores de risco demográficos, biométricos e comportamentais, além do custo anual. O arquivo de referência é o

Custo_Seguro_Saude_Dados.txt e contém as seguintes variáveis:

IDENTIFICAÇÃO	
id_segurado	Código de identificação do segurado.
PERFIL DEMOGRÁFICO	
idade	Idade do segurado, em anos.
sexo	Sexo do segurado.
estado_civil	Estado civil do segurado.
escolaridade	Maior nível de escolaridade concluído.
regiao	Macrorregião do Brasil de residência do segurado.

nro_dependentes	Número de dependentes incluídos no plano.
SAÚDE E HÁBITOS	
imc	Índice de massa corporal (IMC) do segurado.
fumante	Indica se o segurado é fumante.
nro_condicoes_cronicas	Número de condições crônicas de saúde declaradas.
atividade_fisica_regular	Indica se o segurado pratica atividade física regularmente.
historico_familiar_doenca_grave	Indica se há histórico familiar de doença grave.
consumo_alcool	Nível de consumo de álcool (nenhum, baixo, moderado ou alto).
tipo_sanguineo	Tipo sanguíneo do segurado.
VARIÁVEL PRINCIPAL	
custo_anual	Custo anual do segurado para o plano, em R\$.